Problem Set 2: Predicting Poverty

Best Model Deep Dive: por qué gana el LightGBM y qué implica para la focalización

Equipo 02

Jhon Sebastián Vela Salcedo · Cesar Augusto Vallejo Quiroga · Harold Santiago Aguilera Mulfo

Big Data y Machine Learning para Economía Aplicada · 2026-20 · Universidad de los Andes

Best Model Overview: LightGBM clasifica bien porque imputamos el ingreso que el test no trae

Especificación

- **Algoritmo:** LightGBM, clasificación binaria (boosting de árboles)
- **Variables:** 149 a nivel de hogar; 72 construidas, entre ellas el **ingreso imputado** por persona
- **Hiperparámetros:** 15 hojas, 954 rondas, tasa de aprendizaje 0,03, penalización L2 de 50
- **Umbral:** 0,39 (maximiza el F1); validación en 5 pliegues, sin Bogotá

0,78
F1 público en Kaggle

0,77
F1 privado en Kaggle

0,777
F1 en validación cruzada

0,958
AUC

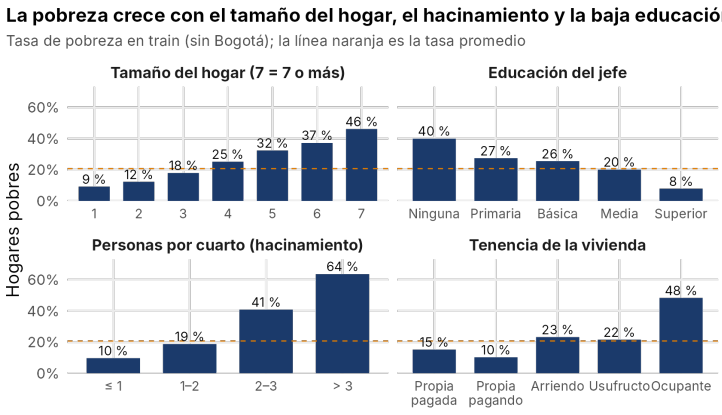
Mensajes principales

1. El salto viene de los **datos**, no del algoritmo: imputar el ingreso suma 0,027 de F1; cambiar Logit por LightGBM, 0,006.
2. Con ese umbral, 18,9 % de los pobres quedan excluidos y 25,4 % de los beneficiarios no son pobres; sin el ingreso imputado, el F1 cae a 0,585–0,675.
3. Su ventaja pública (0,78) **desaparece** en el puntaje privado (0,77), igual al de RF, Elastic Net y logit: la diferencia es ruido.

Contenido: de los datos al modelo y de ahí a la política

2	**Resumen**	Qué modelo ganó, cuánto puntúa en Kaggle y qué mensajes se llevan
4–7	**Datos**	Qué predice la pobreza, por qué imputamos el ingreso y qué variables elegimos
8–12	**Mejor modelo**	Cómo funciona el LightGBM, cómo se ajustó, qué variables pesan y si generaliza
13–15	**Política**	Qué errores comete, quiénes quedan fuera y si se despliega con una encuesta corta

Datos: la pobreza crece con el tamaño del hogar, el hacinamiento y la baja educación



Problema. Un hogar es pobre si su ingreso per cápita queda por debajo de la línea de pobreza.

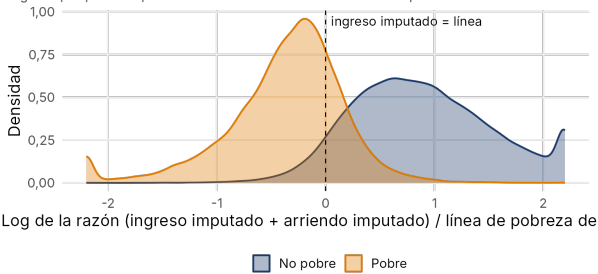
- 20,7 % de los hogares de train son pobres: clase desbalanceada, así que se optimiza el **F1** y se elige el umbral.
- Train: 164.960 hogares; test: 66.168.
- El ingreso, que define la pobreza, **no existe en test**.

Datos: el ingreso no está en test, pero se puede predecir desde las preguntas laborales

1. **Ingreso por persona.** Un LightGBM aprende el ingreso individual con las variables de cada persona que sí están en test (ocupación, horas, posición, afiliación, edad, educación).
2. **Fuera de muestra.** Cada hogar se predice con un modelo que no lo vio (5 pliegues por hogar): sin filtración de train a test.
3. **Regla de pobreza.** Se suma el ingreso imputado al arriendo imputado del propietario y se divide por la línea del hogar.

El ingreso imputado separa a los pobres de los no pobres

Ingreso por persona predicho fuera de muestra con variables que existen en test

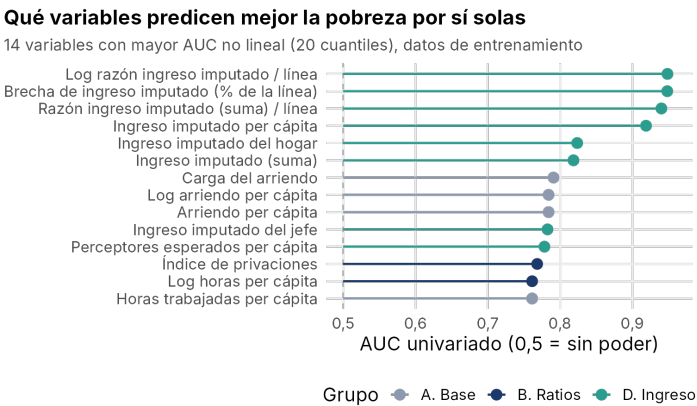


Calidad de la imputación

Correlación con el ingreso del hogar: 0,79; AUC de la razón sola: **0,941**, frente a 0,696 del hacinamiento.

Variables que construyen el ingreso imputado:
horas trabajadas, tamaño de la empresa, cotización a pensión, afiliación a salud, subsidios y bonificaciones, edad y educación.

Datos: el ingreso imputado, por sí solo, ya predice casi tan bien como todas las variables

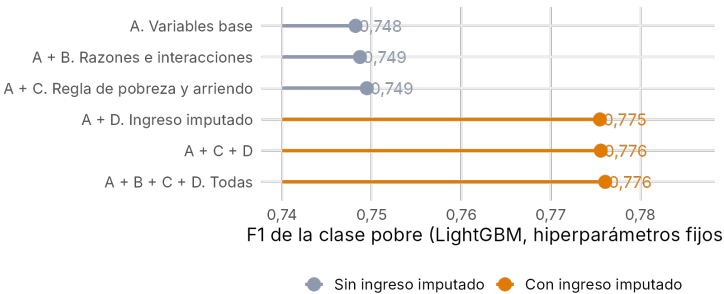


- Probamos cada variable por sí sola con un AUC no lineal (20 cuantiles), para no descartar relaciones en U.
- Las de ingreso imputado (verde) lideran con AUC cercano a 0,95; el arriendo y las horas trabajadas no pasan de 0,8.
- Es la razón entre el ingreso del hogar y la línea de pobreza, la misma regla con que se define la pobreza.
- Con esa lista armamos los grupos A a D que se comparan en la siguiente diapositiva.

Datos: sin el ingreso imputado, el F1 se queda en 0,748; con él, sube a 0,775

El ingreso imputado aporta casi todo el salto de F1

Ablación por grupos de variables



- **A:** 77 variables base de hogar y personas agregadas.
- **B:** razones e interacciones; **C:** estructura de la regla (arriendo imputado).
- **D:** ingreso imputado.
- Solo D mueve el F1; B y C aportan menos de 0,002.

Modelo: LightGBM construye árboles en secuencia, cada uno corrige los errores del anterior

- **Boosting:** suma 954 árboles pequeños de 15 hojas; la tasa de aprendizaje de 0,03 evita que cada árbol sobreajuste.
- **Captura no linealidades e interacciones** sin que las especifiquemos, y maneja categorías (dominio, tenencia).
- **Protocolo:** 11 configuraciones aleatorias con 5 pliegues compartidos y parada temprana; la ganadora se reentrena con tasa baja y número fijo de rondas.
- **Test:** promedio de los 5 modelos entrenados.
- **Umbral** de 0,39, elegido con las predicciones fuera de muestra.

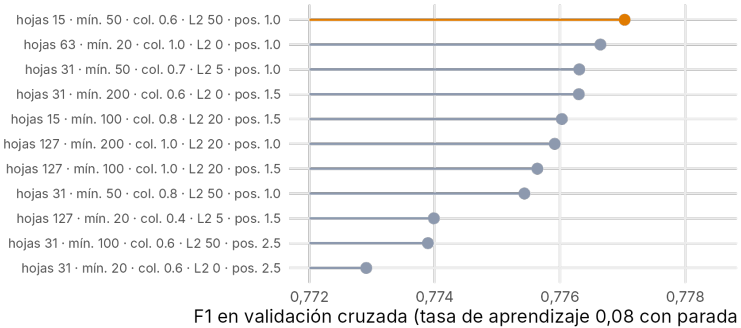
Hiperparámetros finales

Hiperparámetro	Valor
Hojas por árbol	15
Profundidad máxima	6
Mínimo de hogares por hoja	50
Fracción de columnas por árbol	0,6
Fracción de hogares por árbol	0,85
Penalización L2	50
Peso de la clase pobre	1,0
Tasa de aprendizaje	0,03
Rondas (árboles)	954
Umbral de clasificación	0,39

Ajuste: el F1 casi no depende de los hiperparámetros ni del peso de la clase pobre

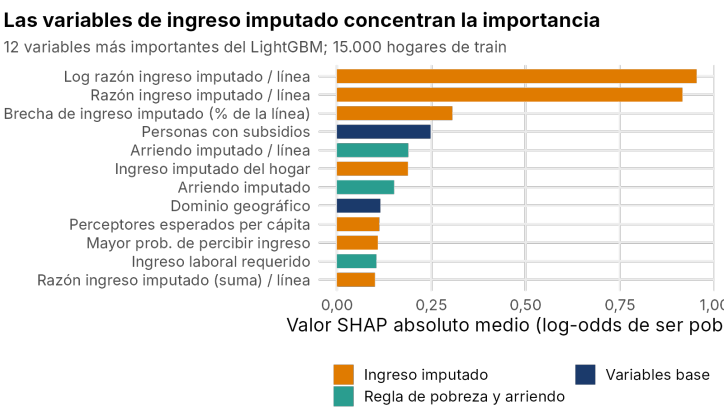
11 configuraciones aleatorias: el F1 casi no depende de los hiperparámetros

Hojas, mínimo de hogares por hoja, fracción de columnas, penalización L2 y peso de la clase pobre



- Las 11 configuraciones van de 0,7729 a 0,7770.
- **Desbalance:** dar más peso a la clase pobre (1,5 y 2,5) **no mejoró**; el mejor modelo usa peso 1.
- Lo que sí ayuda es mover el **umbral**: de 0,5 a 0,39 el F1 sube de 0,768 a 0,777.

Importancia: el ingreso imputado concentra 59 % de la importancia SHAP

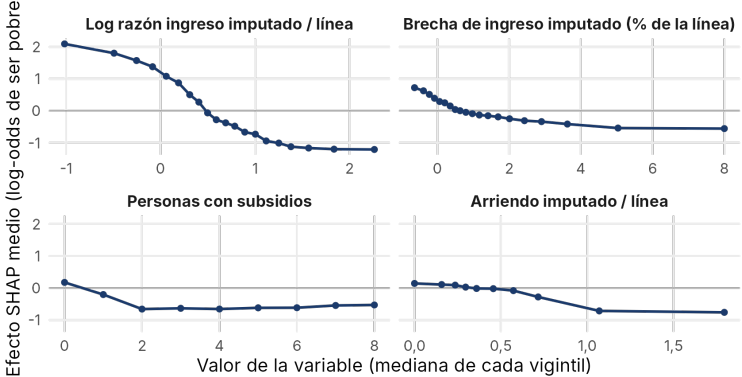


- Las tres primeras variables explican 43 % de la importancia total y son versiones de la razón ingreso imputado / línea.
- Le siguen los **subsidios**, el **arriendo imputado** y el **dominio**.
- Hacinamiento y educación, tan claras en los datos, ya están resumidas en el ingreso imputado.

Qué aprende el modelo: la probabilidad de pobreza cae rápido cuando el ingreso alcanza la línea

Efecto de las variables principales sobre la probabilidad de pobreza

Sobre cero aumenta la probabilidad de ser pobre



- Con ingreso imputado por debajo de la línea (log < 0) el efecto es de **más pobreza**; la caída es abrupta cerca de la línea.
- Recibir subsidios (2 o más personas en el hogar) reduce la probabilidad de pobreza.
- Que el arriendo imputado cubra buena parte de la línea (propietarios) la reduce.

Diagnóstico: el LightGBM lidera el puntaje público (0,78) y empata en el privado (0,77)

F1 con hogares nuevos y con regiones completamente nuevas

Modelo	F1 dentro	F1 fuera	F1 regiones nuevas	Caída
Logit regularizado	0,7719	0,7713	0,7703	0,0010
LightGBM	–	0,7772	0,7741	0,0031

Regiones nuevas: en cada pliegue se dejan fuera dominios geográficos completos.

- **Kaggle:** LightGBM 0,78 público y 0,77 privado; Random Forest, Elastic Net, logit y probit, 0,77 en ambos. El único que cambia es el LightGBM.
- Con la muestra pública (20 % del test) el F1 tiene desviación estándar de $\approx$ 0,0057: una diferencia de 0,01 no es concluyente, y el privado lo confirmó.
- El logit cae 0,0010 al pasar a regiones nuevas; el LightGBM, 0,0031: el boosting depende algo más de las regiones vistas.

Política: el F1 acepta 18,9 % de pobres excluidos y 25,4 % de filtración

Matriz de confusión

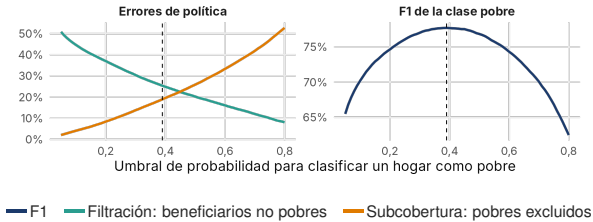
	Predicho pobre	Predicho no pobre
Pobre	25.932 (VP) 81,1 %	6.061 (FN) 18,9 %
No pobre	8.809 (FP) 7,2 %	113.591 (VN) 92,8 %

Hogares y % por fila (sobre la clase real).

Precisión 0,746, **cobertura** 0,811. El F1 pesa por igual excluir a un pobre y beneficiar a un no pobre.

Subir el umbral reduce la filtración pero deja fuera a más pobres

LightGBM, fuera de muestra; línea punteada: umbral que maximiza el F1 (0,39)



¿Preferiría un gobierno otro balance?

Umbral	Pobres excluidos	Beneficiarios no pobres
0,50	25,9 %	20,2 %
0,39 (máx. F1)	**18,9 %**	**25,4 %**
0,23	10 %	34,9 %

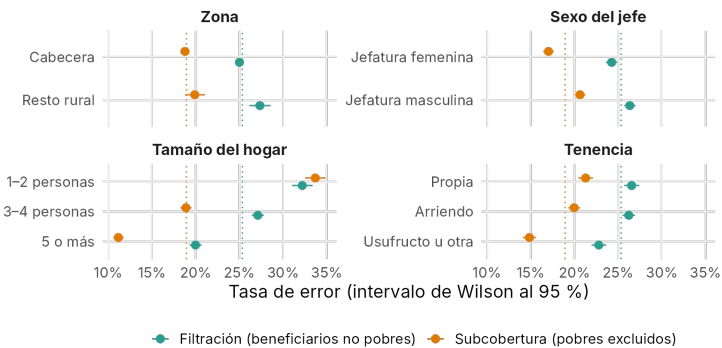
Validación cruzada de 5 pliegues, sin Bogotá.

Para dejar fuera a solo 10 % de los pobres haría falta un umbral de 0,23, y la filtración subiría a 34,9 %. El costo fiscal de ese equilibrio lo decide la política, no el F1.

Política: los pobres de hogares pequeños son los que más se quedan fuera

Los errores no se reparten parejo entre tipos de hogar

LightGBM con el umbral del F1; líneas punteadas: promedio general

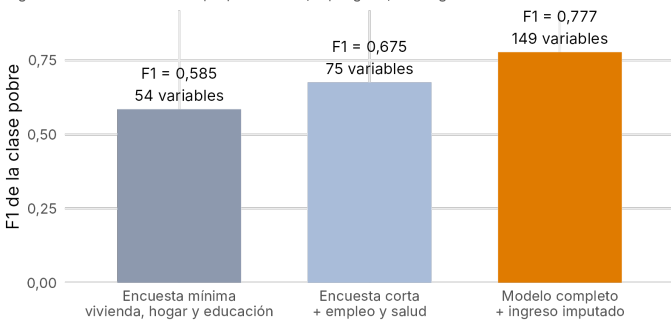


- La subcobertura casi no cambia entre cabecera (18,8 %) y resto rural (19,9 %).
- Pero es mucho mayor en hogares de 1–2 personas (hipótesis: con pocos perceptores, un error en el ingreso imputado cambia al hogar de lado de la línea).
- Un instrumento de focalización debería **revisar con visita** a estos hogares en el umbral.

Política: la encuesta corta depende de cuántas preguntas exige el ingreso imputado

Una encuesta corta cuesta más de 10 puntos de F1

LightGBM con los mismos hiperparámetros; 5 pliegues, sin Bogotá



- Solo con vivienda, composición y educación (54 variables), el F1 es 0,585 y se excluye a 34 % de los pobres. Agregar empleo y salud lo lleva a 0,675.
- Mi ingreso imputado usa unas 60 variables por persona. Otro modelo del equipo, con 8 variables y una primera etapa de ingreso, llegó a 0,77 público y 0,78 privado: **se puede acortar** si esa etapa pide pocas preguntas.

Recomendación

Cuestionario corto *con* las pocas preguntas de ingreso más informativas, no sin ellas; el modelo sirve para **priorizar** hogares a verificar.