Problem Set 2: Predicting Poverty

Algorithm Comparison: qué diferencia a los algoritmos y cuál recomendaríamos

Equipo 02

Jhon Sebastián Vela Salcedo · Cesar Augusto Vallejo Quiroga · Harold Santiago Aguilera Mulfo

Big Data y Machine Learning para Economía Aplicada · 2026-20 · Universidad de los Andes

Best Model Overview: LightGBM gana por poco; los datos explican más que el algoritmo

Especificación del mejor modelo

- **Algoritmo:** LightGBM, clasificación binaria (boosting de árboles)
- **Variables:** 149 a nivel de hogar, con el **ingreso imputado** por persona
- **Hiperparámetros:** 15 hojas, 954 rondas, tasa 0,03, L2 de 50
- **Umbral:** 0,39 (maximiza el F1); validación en 5 pliegues, sin Bogotá

0,78
F1 público en Kaggle

0,78
F1 privado, mejor del equipo

0,777
F1 en validación cruzada

0,007
rango de F1 de cinco algoritmos, mismas variables

Mensajes principales

1. Con las **mismas 40 variables**, cinco de los seis algoritmos quedan a 0,007 de F1; solo Naive Bayes se aleja (0,758).
2. Lo que más mueve el F1 es el ingreso imputado (+0,027), no el algoritmo (+0,006 de Logit a LightGBM).
3. Random Forest y Elastic Net, los contendientes más cercanos, pierden menos de 0,006. El mejor privado (0,78) lo logran modelos con **8 a 20 variables** y la misma idea de ingreso imputado: todo cabe en el ruido de la muestra pública.

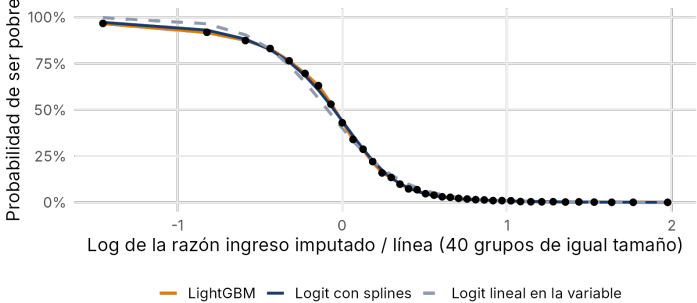
Contenido: de lo que dicen los datos a qué modelo recomendar

2	**Resumen**	Cuál es el mejor modelo y qué dice la comparación en tres mensajes
4–5	**Datos**	Por qué un modelo lineal puede competir con los árboles y cómo se compara de forma justa
6–12	**Comparación**	Los algoritmos exigidos, los dos contendientes más cercanos y qué explica la brecha
13	**Conclusión**	Complejidad, interpretabilidad y desempeño: qué modelo recomendaríamos a una agencia

Datos: la variable clave es casi logística, por eso un modelo lineal compite con los árboles

La variable clave es casi logística: un logit con splines la captura

Puntos negros: tasa observada de pobreza; líneas: ajustes con solo esta variable



- La probabilidad de pobreza depende sobre todo de la **razón ingreso imputado / línea**, con forma de S.
- Un logit con splines sobre esa variable queda casi pegado al LightGBM.
- Los árboles ganan donde hay interacciones; después de construir esa razón quedan pocas.
- El desbalance (20,7 % pobres) se maneja con el **umbral**: de 0,5 a 0,39 el F1 sube 0,009.

Datos: una comparación justa fija predictores, pliegues y regla de umbral

- **Mismas 40 variables** para los seis algoritmos, las de mayor importancia SHAP (selección con un modelo auxiliar).
- **Mismos 5 pliegues** de hogares y la misma métrica: F1 de la clase pobre, sin Bogotá (no existe en test).
- **Mismo umbral:** el que maximiza el F1 con las predicciones fuera de muestra; cada algoritmo ajusta su umbral, no el puntaje de Kaggle.
- **Mismo preprocesamiento:** los modelos lineales usan log1p, winsorización y dummies; los árboles, las variables sin transformar.

Qué cambia entre algoritmos

Solo la forma funcional y la regularización: lineal sin penalizar (LPM, Logit), penalizado (Elastic Net), promedio de árboles (Random Forest), árboles en secuencia (LightGBM) y probabilidades condicionales independientes (Naive Bayes).

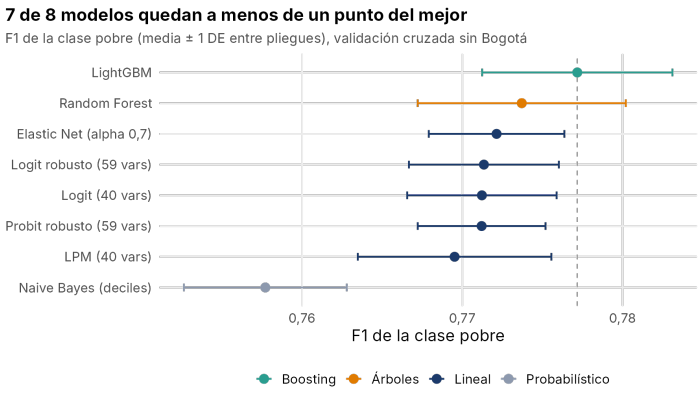
Las versiones enviadas a Kaggle usan más variables (LightGBM, 149; Elastic Net, 102 columnas con splines; Logit, 59). Entre versiones de distinto protocolo solo se compara el puntaje de Kaggle.

Resumen: la mejor versión de cada uno de los seis algoritmos

		Validación cruzada			Kaggle		
Algoritmo	**Versión de referencia**	**F1**	**Prec.**	**Cob.**	**Envíos**	**Máx. público**	**Máx. privado**
Boosting	LightGBM, 149 var.	0,777	0,746	0,811	7	0,78	0,78
Random Forest	ranger, 40 var.	0,774	0,748	0,801	4	0,77	0,78
Elastic Net	glmnet, splines	0,772	0,730	0,819	5	0,77	0,77
Logit	regularizado, 59 var.	0,771	0,739	0,806	4	0,77	0,77
LPM	MCO, 40 var.	0,770	0,728	0,816	1	0,74	0,75
Naive Bayes	deciles, 40 var.	0,758	0,694	0,834	1	0,64	0,65

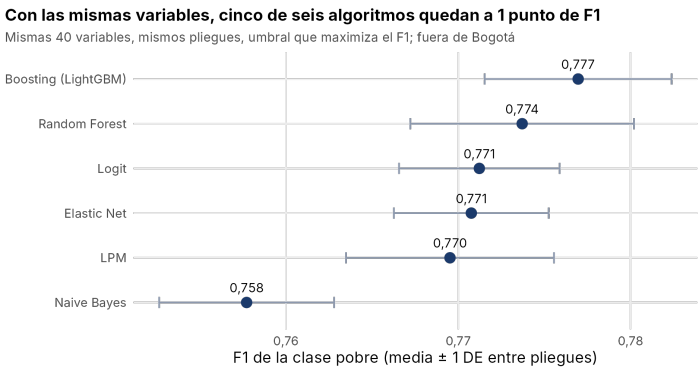
Validación cruzada de la versión de referencia: 5 pliegues, sin Bogotá, umbral que maximiza el F1. Kaggle: mejor puntaje público y mejor privado entre los envíos de cada algoritmo.

Con cada algoritmo en su mejor versión, siete de ocho modelos quedan a menos de un punto



- Las barras (±1 DE entre pliegues) se traslapan: la mayoría de las diferencias es del tamaño del ruido.
- Cada modelo usa sus propias variables (40, 59 o 149), así que esta comparación aún no es justa.
- Solo Naive Bayes queda claramente atrás: supone variables independientes, y aquí no lo son.

Con las mismas variables, cinco de seis algoritmos quedan a menos de un punto de F1



- El Elastic Net con 40 variables queda en 0,771: la penalización casi no actúa porque hay 165 mil hogares para pocos parámetros.
- **Naive Bayes** rinde menos: supone independencia entre variables que están muy correlacionadas.

Contendiente 1, Random Forest: promedia árboles y, con 20 variables, llega a 0,78 privado

- **Bosque:** cientos de árboles profundos y decorrelacionados promedian el ruido.
- **Boosting:** cada árbol corrige el residuo del anterior y reduce el sesgo.
- Ambos priorizan la razón ingreso imputado / línea y variantes de ella.

Dos versiones del mismo algoritmo

	Versión A	Versión B
Variables	40	20
Árboles; hoja mínima	500; 150	360; 156
F1 (validación cruzada)	0,774	0,778
Precisión / cobertura	0,748 / 0,801	0,740 / 0,820
Kaggle público / privado	0,77 / 0,77	0,77 / 0,78

Referencia, LightGBM de 149 variables: F1 0,777, precisión 0,746, cobertura 0,811.

Posición de cada variable en la importancia

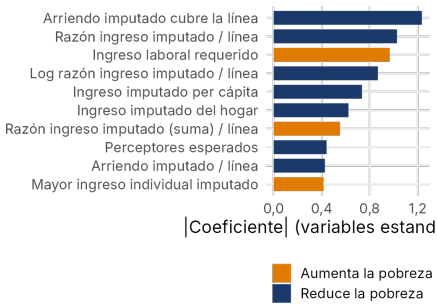
Variable	LightGBM	Random Forest	Elastic Net
Log razón ingreso imputado / línea	1	2	4
Razón ingreso imputado / línea	2	1	2
Arriendo imputado cubre la línea	39	–	1
Brecha de ingreso imputado (Ingreso laboral requerido	11	9	3
Personas con subsidios	4	4	12
Arriendo imputado / línea	5	5	9
Ingreso imputado per cápita	33	29	5
Ingreso imputado del hogar	6	6	6

LightGBM y Random Forest: valor SHAP absoluto medio; Elastic Net: mayor coeficiente estandarizado en valor absoluto. "–": fuera del modelo. El F1 de las dos versiones viene de protocolos de validación distintos.

Contendiente 2, Elastic Net: casi los mismos hogares, con coeficientes que se pueden leer

Elastic Net: 10 mayores coeficientes

Coeficiente de mayor tamaño entre la variable y sus splines



LightGBM frente a Elastic Net: hogares clasificados distinto

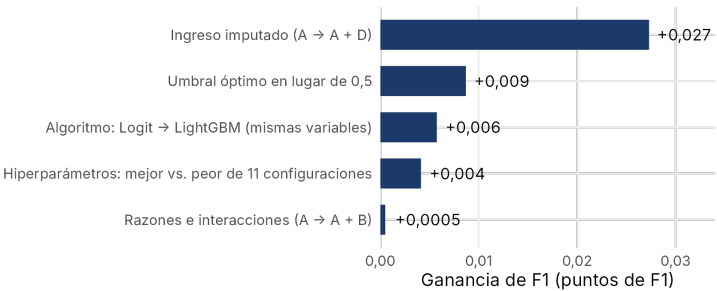
Clasificación	Hogares	% del total	% realmente pobres
Ambos: pobre	33.514	21,7	76
Ambos: no pobre	117.275	76,0	4
Solo LightGBM: pobre	1.227	0,8	42
Solo Elastic Net: pobre	2.377	1,5	34

- Los modelos discrepan en 2,3 % de los hogares y en ellos solo 37 % son pobres: son casos de frontera.
- Los coeficientes del Elastic Net recuperan lo mismo que el SHAP: dominan la razón ingreso imputado y el arriendo imputado.

Qué explica la brecha: ingreso imputado, umbral y luego el algoritmo

Los datos pesan más que el algoritmo

Ganancia de F1 asociada a cada decisión de modelado



- Pasar de las variables base a las de ingreso imputado vale 0,027: cuatro veces más que cambiar de algoritmo.
- Elegir el **umbral** sobre las probabilidades vale más que el algoritmo.
- Afinar los hiperparámetros mueve el F1 0,0041 entre la mejor y la peor de 11 configuraciones.
- **Lo replica otro modelo del equipo:** sin las variables de la primera etapa su F1 baja de ≈0,777 a 0,765 (LightGBM), 0,761 (XGBoost) y 0,721 (RF); con 1.152 variables de persona y sin primera etapa llega a 0,773.

Más allá del Kaggle: el logit regularizado se parece al LightGBM y es más estable

F1 en hogares nuevos y en regiones nuevas

Modelo	F1 dentro	F1 fuera	F1 regiones nuevas	Caída
Logit regularizado	0,7719	0,7713	0,7703	0,0010
LightGBM	–	0,7772	0,7741	0,0031

Regiones nuevas: en cada pliegue se dejan fuera dominios geográficos completos.

- Entre logit regularizado (0,771) y LightGBM (0,777) hay 0,006 de F1.
- En una muestra del tamaño del leaderboard público, la desviación estándar del F1 es 0,0057: la diferencia es del tamaño del ruido.
- Dentro y fuera de muestra el logit casi no cambia (brecha 0,0006); con regiones nuevas, cae 0,0010 contra 0,0031 del boosting.

Conclusión: el mejor puntaje público no tiene por qué ser el modelo que recomendaríamos

Modelo	F1 (CV)	Variables	Interpretación	Caída, regiones nuevas
LightGBM	0,777	149	SHAP, no coeficientes	cae 0,0031
LightGBM, 8 variables	0,777*	8	SHAP; pocas variables	no medida
Random Forest	0,774	40	importancia global	no medida
Logit regularizado	0,771	59	coeficientes y signos	cae 0,0010

* Validación propia de este modelo (anidada, sin Bogotá); no es comparable con las demás filas.

Qué dice la comparación

La complejidad compra **menos de un punto de F1**: con 8 variables, un modelo logra el mejor privado (0,78). La información (el ingreso imputado) explica casi todo y es lo difícil de desplegar: necesita el módulo laboral de cada persona.

Recomendación

Para una agencia: el **logit regularizado**, auditable y estable entre regiones, con el LightGBM como control. Si se busca el máximo puntaje, LightGBM; la elección depende de cuánto valore la agencia explicar cada exclusión.